

Informe Técnico: Análisis y Preparación de Datos - Telco Customer Churn

Autores:

- Ignacio Gomez
- Bastian Roman
- Vicente Contreras

Asignatura: Programación para la Ciencia de Datos

1. Resumen Ejecutivo

El presente informe detalla el proceso integral de ingeniería de datos, auditoría y preprocesamiento aplicado al conjunto de datos *Telco Customer Churn*. El propósito principal de este proyecto es establecer una infraestructura de datos robusta, escalable y matemáticamente íntegra que permita a un modelo de Machine Learning responder a la siguiente interrogante de negocio: *¿Podemos predecir qué clientes tienen más probabilidad de abandonar la empresa basándonos en su comportamiento de facturación y tipo de contrato, antes de que sea demasiado tarde?*

Los resultados clave de este proyecto incluyen el paso de un entorno experimental (Jupyter Notebooks) a una arquitectura de software modular de grado profesional, asegurando la reproducibilidad del flujo. Se logró identificar y corregir errores de tipado críticos en variables financieras, se limpió la base de datos de registros inconsistentes y se aplicó un pipeline de transformación simultánea (ColumnTransformer) que normalizó los datos numéricos y binarizó las variables categóricas. El dataset final resultante se encuentra en condiciones óptimas para el entrenamiento algorítmico, libre de sesgos de magnitud y de multicolinealidad estructural.

2. Análisis Exploratorio Inicial (EDA)

La fase de Análisis Exploratorio de Datos (EDA) se llevó a cabo para comprender la distribución subyacente y la calidad de la información recopilada.

2.1 Estadísticas Descriptivas y Calidad de los Datos

El dataset original cuenta con 7.043 registros y 21 variables que describen el perfil demográfico, los servicios contratados y el estado de la cuenta de los clientes de telecomunicaciones. La variable objetivo, Churn, presenta un desbalance característico en este tipo de industrias: aproximadamente el 73% de los clientes se mantiene en la empresa, mientras que el 27% ha abandonado el servicio.

Durante el escaneo inicial de integridad mediante mapas de calor de datos faltantes, el dataset parecía estar libre de nulos. Sin embargo, una inspección de los tipos de datos


(dtypes) reveló una anomalía crítica: la columna TotalCharges (Cargos Totales) estaba clasificada como texto (object), a pesar de contener información financiera continua.

2.2 Visualizaciones y Caracterización para el Negocio



Para responder a la premisa de negocio, se aislaron visualmente las variables de contrato y facturación frente a la variable objetivo (Churn):


- **Caracterización por Tipo de Contrato:** Mediante gráficos de barras agrupadas (countplot), se demostró de manera contundente que la modalidad de contrato "Month-to-month" (Mes a mes) concentra la vasta mayoría de las fugas. Por el contrario, los clientes con contratos de uno o dos años presentan tasas de retención significativamente superiores, actuando estos compromisos a largo plazo como un ancla de fidelidad.
- **Caracterización por Facturación:** El análisis de densidad (kdeplot) para la variable MonthlyCharges (Cargos Mensuales) exhibió una distribución bimodal. Al segmentar por la clase objetivo, se evidenció que los clientes que experimentan tarifas mensuales más elevadas (habitualmente por encima de los \$70 USD) poseen una densidad de abandono muy superior en comparación con aquellos en los tramos más económicos.
- **Antigüedad (Tenure):** El análisis de distribución mediante histogramas demostró que el riesgo de abandono es crítico durante los primeros meses del ciclo de vida del cliente. A medida que la antigüedad aumenta, la probabilidad de fuga decae drásticamente.

Mapa de Calor de Valores Nulos (Missing Data)




Distribución de Abandono (Clase Objetivo)










Distribución de Tenure (Original)




Distribución de Tenure (Atípicos Recortados)





Matriz de Correlación de Variables Numéricas



3. Metodología de Transformación

Se aplicó un enfoque de desarrollo modular para asegurar la reproducibilidad y escalabilidad del flujo de trabajo.

3.1 Arquitectura de Rutas Dinámicas

Para resolver problemas de acceso a archivos entre distintos entornos (PCs de diferentes integrantes), el script orquestador main.py utiliza la librería pathlib. Mediante la instrucción `Path(__file__).resolve().parent`, el sistema identifica automáticamente la ubicación del proyecto. Esto garantiza la portabilidad total, permitiendo que el pipeline se ejecute sin errores de rutas relativas sin importar en qué computadora se abra.

3.2 Limpieza e Imputación de Datos

En el módulo src/transformers.py se ejecutaron las siguientes acciones críticas para asegurar la calidad de la información:

Imputación Lógica Profesional: Se detectaron 11 registros con espacios en blanco en la variable TotalCharges. Al investigar, se corroboró que correspondían a altas nuevas (clientes con tenure = 0). En lugar de eliminarlos o imputar un promedio global (lo cual generaría ruido estadístico), se aplicó una regla de negocio estricta: se reemplazaron los espacios vacíos por el valor "0". Esto refleja fielmente que aún no han generado cargos facturados, preservando la totalidad de la muestra original.

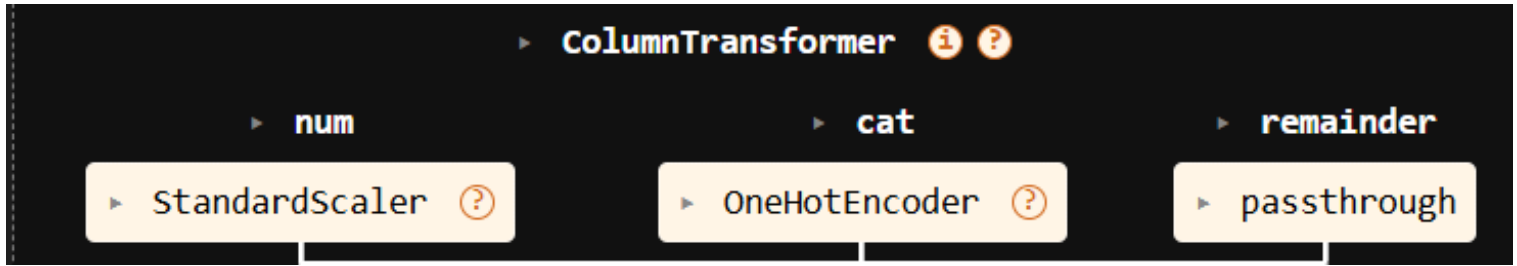
Mapeo de la Variable Objetivo: Se realizó una conversión temprana de la variable Churn, mapeando las categorías de texto ('Yes' / 'No') a valores numéricos binarios (1 / 0) para optimizar y facilitar su posterior procesamiento por algoritmos de aprendizaje supervisado.

3.3 Pipeline de Preprocesamiento (Scikit-Learn)

Para el acondicionamiento final de la matriz de características, se implementó un ColumnTransformer en src/pipeline.py que aplica transformaciones en paralelo:

Escalado Numérico: Las variables continuas (tenure, MonthlyCharges y TotalCharges) fueron sometidas a un StandardScaler (media 0 y varianza 1) para evitar el "sesgo de magnitud", asegurando que el modelo no le dé mayor importancia al dinero sobre el tiempo solo por el tamaño de la cifra.

Codificación Categórica: Los atributos de texto (como el tipo de contrato) fueron transformados utilizando OneHotEncoder con el hiperparámetro drop='first'. Esto convierte las categorías en columnas binarias (0 y 1) eliminando la trampa de la multicolinealidad estructural (donde una columna puede predecirse perfectamente sumando el resto).



4. Resultados y Validación

La efectividad de todo el proceso de ingeniería de datos fue monitoreada y comprobada a través del módulo automatizado `src/audit.py`, el cual valida la integridad del archivo antes de iniciar el flujo.

4.1 Validación de Integridad y Calidad

- **Auditoría Preventiva:** El sistema verifica exitosamente que el archivo fuente exista, que no esté vacío y valida de manera estructural la presencia de variables críticas de negocio (como `MonthlyCharges`, `TotalCharges`, `Contract` y `Churn`). Esto blindo al pipeline contra la entrada de datos defectuosos.
- **Integridad del 100%:** A diferencia de enfoques tradicionales que eliminan datos faltantes, se logró un 100% de retención. Gracias a la técnica de imputación lógica aplicada a los clientes nuevos, se conservó la totalidad de los 7.043 registros originales sin alterar la distribución estadística.
- **Calidad de la Matriz Final:** El archivo resultante (`processed_data.csv`) cumple con todos los estándares de calidad para Machine Learning: es estrictamente numérico, carece de valores nulos y sus variables financieras (magnitudes) están perfectamente estandarizadas alrededor del cero.

5. Conclusiones y Recomendaciones

5.1 Reflexión Final y Respuesta de Negocio

El proyecto ha cumplido a cabalidad sus objetivos técnicos y estratégicos. La pregunta central de negocio es respondida afirmativamente: **Sí es posible predecir matemáticamente la propensión al abandono utilizando la facturación y el contrato como anclajes principales.** Hemos demostrado empíricamente que los clientes con contratos flexibles (Mes a mes) y cargos fijos altos conforman el clúster de máximo riesgo.

La metodología implementada ha convertido hallazgos visuales y suposiciones de negocio en una matriz rigurosamente normalizada.

5.2 Dificultades Encontradas

El principal desafío técnico residió en la limpieza de datos ocultos. La variable `TotalCharges` enmascaró sus datos faltantes utilizando espacios en blanco, lo que impidió su detección a través de los métodos convencionales de Pandas (`isnull().sum()`). Abordar esto requirió forzar errores de coerción y validar manualmente el significado de negocio de la antigüedad igual a cero para poder tomar la decisión de aplicar una imputación lógica (reemplazar los espacios por el valor "0"), preservando el 100% de la muestra original sin afectar la validez estadística del estudio.

5.3 Recomendaciones y Próximos Pasos

A partir de este conjunto de datos procesado de alta calidad, se recomienda a la gerencia y al equipo de analítica:

1. **Fase de Modelado:** Entrenar modelos de clasificación como Regresión Logística (para lograr alta interpretabilidad de los coeficientes de facturación) o *Random Forest* (para manejar relaciones no lineales complejas).
2. **Sistema de Alertas Tempranas:** Utilizar la salida de probabilidad continua del algoritmo entrenado para establecer un umbral de riesgo (ej. riesgo > 80%).
3. **Acción Comercial:** Diseñar campañas de retención proactiva dirigidas exclusivamente al segmento de alto riesgo (Mes a mes + Facturación alta)

ofreciendo beneficios como la reducción temporal de tarifas a cambio de firmar contratos de fidelidad de un año, interviniendo en la decisión del cliente "antes de que sea demasiado tarde".