

# **Informe Técnico: Análisis y Preparación de Datos - Telco Customer Churn**

**Autores:**

- Ignacio Gomez
- Bastian Roman
- Vicente Contreras

**Asignatura:** Programación para la Ciencia de Datos

|                                                                               |           |
|-------------------------------------------------------------------------------|-----------|
| 1. Resumen Ejecutivo.....                                                     | 3         |
| 2. Análisis Exploratorio Inicial (EDA).....                                   | 3         |
| 2.1 Estadísticas Descriptivas y Calidad de los Datos.....                     | 3         |
| 2.2 Visualizaciones y Caracterización para el Negocio.....                    | 4         |
| 3. Metodología de Transformación.....                                         | 10        |
| 3.1 Arquitectura de Rutas Dinámicas.....                                      | 10        |
| 3.2 Limpieza e Imputación de Datos.....                                       | 10        |
| 3.3 Pipeline de Preprocesamiento (Scikit-Learn).....                          | 10        |
| 4. Resultados y Validación.....                                               | 11        |
| 4.1 Validación de Integridad y Calidad.....                                   | 11        |
| 5. Conclusiones y Recomendaciones.....                                        | 12        |
| 5.1 Reflexión Final y Respuesta de Negocio.....                               | 12        |
| 5.2 Dificultades Encontradas.....                                             | 12        |
| 5.3 Recomendaciones y Próximos Pasos.....                                     | 12        |
| 6. OPTIMIZACIÓN DE HIPERPARAMETROS.....                                       | 13        |
| 7. Modelado Supervisado.....                                                  | 15        |
| 7.1 Implementación de Modelos Supervisados.....                               | 16        |
| Regresión Logística.....                                                      | 16        |
| Random Forest.....                                                            | 16        |
| Decision Tree (Árbol de Decisión).....                                        | 17        |
| K-Nearest Neighbors (KNN).....                                                | 17        |
| Gráficos del modelo.....                                                      | 18        |
| 8. TÉCNICAS NO SUPERVISADAS.....                                              | 18        |
| 8.2 K-MEANS.....                                                              | 18        |
| 8.3 DENDROGRAMA Y CLUSTERING JERÁRQUICO.....                                  | 21        |
| <b>9. Conclusiones.....</b>                                                   | <b>22</b> |
| 9.1. Análisis Multivariado de Trade-offs mediante Visualización Avanzada..... | 22        |
| 9.2. Justificación de la Simulación Operativa del Umbral.....                 | 22        |
| 9.3. Propuesta de Plan de Acción Comercial Basado en Modelos.....             | 23        |

## 1. Resumen Ejecutivo

El presente informe detalla el proceso integral de ingeniería de datos, auditoría y preprocesamiento aplicado al conjunto de datos *Telco Customer Churn*. El propósito principal de este proyecto es establecer una infraestructura de datos robusta, escalable y matemáticamente íntegra que permita a un modelo de Machine Learning responder a la siguiente interrogante de negocio: *¿Podemos predecir qué clientes tienen más probabilidad de abandonar la empresa basándonos en su comportamiento de facturación y tipo de contrato, antes de que sea demasiado tarde?*

Los resultados clave de este proyecto incluyen el paso de un entorno experimental (Jupyter Notebooks) a una arquitectura de software modular de grado profesional, asegurando la reproducibilidad del flujo. Se logró identificar y corregir errores de tipado críticos en variables financieras, se limpió la base de datos de registros inconsistentes y se aplicó un pipeline de transformación simultánea (ColumnTransformer) que normalizó los datos numéricos y binarizó las variables categóricas. El dataset final resultante se encuentra en condiciones óptimas para el entrenamiento algorítmico, libre de sesgos de magnitud y de multicolinealidad estructural.

## 2. Análisis Exploratorio Inicial (EDA)

La fase de Análisis Exploratorio de Datos (EDA) se llevó a cabo para comprender la distribución subyacente y la calidad de la información recopilada.

### 2.1 Estadísticas Descriptivas y Calidad de los Datos

El dataset original cuenta con 7.043 registros y 21 variables que describen el perfil demográfico, los servicios contratados y el estado de la cuenta de los clientes de telecomunicaciones. La variable objetivo, Churn, presenta un desbalance característico en este tipo de industrias: aproximadamente el 73% de los clientes se mantiene en la empresa, mientras que el 27% ha abandonado el servicio.


Durante el escaneo inicial de integridad mediante mapas de calor de datos faltantes, el dataset parecía estar libre de nulos. Sin embargo, una inspección de los tipos de datos (dtypes) reveló una anomalía crítica: la columna TotalCharges (Cargos Totales) estaba clasificada como texto (object), a pesar de contener información financiera continua.

## 2.2 Visualizaciones y Caracterización para el Negocio



Para responder a la premisa de negocio, se aislaron visualmente las variables de contrato y facturación frente a la variable objetivo (Churn):


- **Caracterización por Tipo de Contrato:** Mediante gráficos de barras agrupadas (countplot), se demostró de manera contundente que la modalidad de contrato "Month-to-month" (Mes a mes) concentra la vasta mayoría de las fugas. Por el contrario, los clientes con contratos de uno o dos años presentan tasas de retención significativamente superiores, actuando estos compromisos a largo plazo como un ancla de fidelidad.
- **Caracterización por Facturación:** El análisis de densidad (kdeplot) para la variable MonthlyCharges (Cargos Mensuales) exhibió una distribución bimodal. Al segmentar por la clase objetivo, se evidenció que los clientes que experimentan tarifas mensuales más elevadas (habitualmente por encima de los \$70 USD) poseen una densidad de abandono muy superior en comparación con aquellos en los tramos más económicos.
- **Antigüedad (Tenure):** El análisis de distribución mediante histogramas demostró que el riesgo de abandono es crítico durante los primeros meses del ciclo de vida del cliente. A medida que la antigüedad aumenta, la probabilidad de fuga decae drásticamente.

Mapa de Calor de Valores Nulos (Missing Data)




Distribución de Abandono (Clase Objetivo)










Distribución de Tenure (Original)




Distribución de Tenure (Atípicos Recortados)







Matriz de Correlación de Variables Numéricas



### 3. Metodología de Transformación

Se aplicó un enfoque de desarrollo modular para asegurar la reproducibilidad y escalabilidad del flujo de trabajo.

#### 3.1 Arquitectura de Rutas Dinámicas

Para resolver problemas de acceso a archivos entre distintos entornos (PCs de diferentes integrantes), el script orquestador main.py utiliza la librería pathlib. Mediante la instrucción `Path(__file__).resolve().parent`, el sistema identifica automáticamente la ubicación del proyecto. Esto garantiza la portabilidad total, permitiendo que el pipeline se ejecute sin errores de rutas relativas sin importar en qué computadora se abra.

#### 3.2 Limpieza e Imputación de Datos

En el módulo src/transformers.py se ejecutaron las siguientes acciones críticas para asegurar la calidad de la información:

**Imputación Lógica Profesional:** Se detectaron 11 registros con espacios en blanco en la variable TotalCharges. Al investigar, se corroboró que correspondían a altas nuevas (clientes con tenure = 0). En lugar de eliminarlos o imputar un promedio global (lo cual generaría ruido estadístico), se aplicó una regla de negocio estricta: se reemplazaron los espacios vacíos por el valor "0". Esto refleja fielmente que aún no han generado cargos facturados, preservando la totalidad de la muestra original.


**Mapeo de la Variable Objetivo:** Se realizó una conversión temprana de la variable Churn, mapeando las categorías de texto ('Yes' / 'No') a valores numéricos binarios (1 / 0) para optimizar y facilitar su posterior procesamiento por algoritmos de aprendizaje supervisado.

#### 3.3 Pipeline de Preprocesamiento (Scikit-Learn)

Para el acondicionamiento final de la matriz de características, se implementó un ColumnTransformer en src/pipeline.py que aplica transformaciones en paralelo:

**Escalado Numérico:** Las variables continuas (tenure, MonthlyCharges y TotalCharges) fueron sometidas a un StandardScaler (media 0 y varianza 1) para evitar el "sesgo de magnitud", asegurando que el modelo no le dé mayor importancia al dinero sobre el tiempo solo por el tamaño de la cifra.

**Codificación Categórica:** Los atributos de texto (como el tipo de contrato) fueron transformados utilizando OneHotEncoder con el hiperparámetro drop='first'. Esto convierte las categorías en columnas binarias (0 y 1) eliminando la trampa de la multicolinealidad estructural (donde una columna puede predecirse perfectamente sumando el resto).



## 4. Resultados y Validación

La efectividad de todo el proceso de ingeniería de datos fue monitoreada y comprobada a través del módulo automatizado src/audit.py, el cual valida la integridad del archivo antes de iniciar el flujo.

### 4.1 Validación de Integridad y Calidad

- **Auditoría Preventiva:** El sistema verifica exitosamente que el archivo fuente exista, que no esté vacío y valida de manera estructural la presencia de variables críticas de negocio (como MonthlyCharges, TotalCharges, Contract y Churn). Esto blindo al pipeline contra la entrada de datos defectuosos.
- **Integridad del 100%:** A diferencia de enfoques tradicionales que eliminan datos faltantes, se logró un 100% de retención. Gracias a la técnica de imputación lógica aplicada a los clientes nuevos, se conservó la totalidad de los 7.043 registros originales sin alterar la distribución estadística.
- **Calidad de la Matriz Final:** El archivo resultante (processed\_data.csv) cumple con todos los estándares de calidad para Machine Learning: es estrictamente numérico, carece de valores nulos y sus variables financieras (magnitudes) están perfectamente estandarizadas alrededor del cero.

## 5. Conclusiones y Recomendaciones

### 5.1 Reflexión Final y Respuesta de Negocio

El proyecto ha cumplido a cabalidad sus objetivos técnicos y estratégicos. La pregunta central de negocio es respondida afirmativamente: **Sí es posible predecir matemáticamente la propensión al abandono utilizando la facturación y el contrato como anclajes principales.** Hemos demostrado empíricamente que los clientes con contratos flexibles (Mes a mes) y cargos fijos altos conforman el clúster de máximo riesgo.

La metodología implementada ha convertido hallazgos visuales y suposiciones de negocio en una matriz rigurosamente normalizada.

### 5.2 Dificultades Encontradas

El principal desafío técnico residió en la limpieza de datos ocultos. La variable TotalCharges enmascaró sus datos faltantes utilizando espacios en blanco, lo que impidió su detección a través de los métodos convencionales de Pandas (`isnull().sum()`). Abordar esto requirió forzar errores de coerción y validar manualmente el significado de negocio de la antigüedad igual a cero para poder tomar la decisión de aplicar una imputación lógica (reemplazar los espacios por el valor "0"), preservando el 100% de la muestra original sin afectar la validez estadística del estudio.

### 5.3 Recomendaciones y Próximos Pasos

A partir de este conjunto de datos procesado de alta calidad, se recomienda a la gerencia y al equipo de analítica:

1. **Fase de Modelado:** Entrenar modelos de clasificación como Regresión Logística (para lograr alta interpretabilidad de los coeficientes de facturación) o *Random Forest* (para manejar relaciones no lineales complejas).
2. **Sistema de Alertas Tempranas:** Utilizar la salida de probabilidad continua del algoritmo entrenado para establecer un umbral de riesgo (ej. riesgo > 80%).
3. **Acción Comercial:** Diseñar campañas de retención proactiva dirigidas exclusivamente al segmento de alto riesgo (Mes a mes + Facturación alta) ofreciendo beneficios como la reducción temporal de tarifas a cambio de firmar contratos de fidelidad de un año, interviniendo en la decisión del cliente "antes de que sea demasiado tarde"

## Evaluación 2


### 6. OPTIMIZACIÓN DE HIPERPARAMETROS

El proceso de sintonización paramétrica de las arquitecturas predictivas se implementó mediante el framework de optimización automatizada Optuna. Esta herramienta de computación analítica permite explorar el espacio de búsqueda paramétrico de manera eficiente a través de algoritmos de muestreo probabilístico, evitando los costos computacionales de las búsquedas exhaustivas tradicionales. En este diseño experimental, la optimización se programó con el objetivo de maximizar la métrica F1-Score, debido a su idoneidad en contextos de clasificación con desbalance de clases, al ponderar de forma armónica la precisión y la sensibilidad sin sesgar el rendimiento del estimador hacia la clase mayoritaria.


La configuración metodológica de la búsqueda contempló la ejecución de 8 ensayos independientes (trials), integrados con una validación cruzada estructurada en 3 pliegues (3 folds). Este diseño generó un total de 24 entrenamientos reales calculados matemáticamente. Como resultado de este proceso exploratorio, el modelo de Regresión Logística (Logistic Regression) fue seleccionado para la consolidación definitiva del pipeline. Los valores específicos finales correspondientes a la constante de regularización C y al resolovedor matemático (solver) no fueron reportados por la ejecución del proyecto.

Durante la etapa de validación cruzada, la configuración seleccionada alcanzó un F1-Score promedio de 0.5980. Posteriormente, para evaluar la capacidad de generalización ante datos no observados durante el entrenamiento, se utilizó el conjunto de prueba de control (Test). La evaluación analítica final se ejecutó aplicando un umbral de decisión (threshold) ajustado a 0.35. Bajo estas condiciones operativas, el clasificador obtuvo un F1-Score definitivo de 0.6148 y un Área Bajo la Curva ROC (AUC) de 0.8419, lo que refleja un desempeño predictivo estable y una adecuada capacidad de discriminación entre los perfiles de usuarios estables y aquellos en situación de abandono.

El análisis detallado de la matriz de confusión operativa en el conjunto de prueba registra los siguientes resultados cuantitativos: 812 verdaderos negativos (TN), correspondientes a usuarios estables correctamente clasificados; 223 falsos positivos (FP), representados por alertas de fuga erróneas que implican un gasto en campañas de marketing de retención sobre clientes que no planeaban abandonar el servicio; 109 falsos negativos (FN), que constituyen el segmento crítico de clientes que rescindieron sus contratos sin ser detectados de forma temprana por el algoritmo; y 265 verdaderos positivos (TP), que reflejan las bajas contractuales anticipadas de forma correcta. Estos resultados exponen el compromiso analítico del modelo bajo el umbral de 0.35, donde se prioriza incrementar la sensibilidad para capturar una mayor proporción de abandonos reales a expensas de asumir un incremento controlado en la tasa de falsas alarmas.



| LogisticRegression ⓘ ? |  |                    |
|------------------------|--|--------------------|
| Parameters             |  |                    |
| penalty                |  | 'deprecated'       |
| C                      |  | 1.2633157348962447 |
| l1_ratio               |  | 0.0                |
| dual                   |  | False              |
| tol                    |  | 0.0001             |
| fit_intercept          |  | True               |
| intercept_scaling      |  | 1                  |
| class_weight           |  | None               |
| random_state           |  | 42                 |
| solver                 |  | 'liblinear'        |
| max_iter               |  | 1000               |
| verbose                |  | 0                  |
| warm_start             |  | False              |
| n_jobs                 |  | None               |



## 7. Modelado Supervisado

El desarrollo de la fase predictiva de este proyecto se enmarca dentro del aprendizaje automático supervisado, un paradigma donde el algoritmo aprende una función de mapeo  $f(X) = Y$  a partir de pares de datos de entrenamiento empíricos que contienen tanto las características independientes de los clientes como sus respectivas etiquetas de clase. Específicamente, la problemática de la rotación de clientes (Telco Churn) constituye un problema de clasificación binaria. En este escenario, el espacio de las etiquetas de salida está acotado discretamente a un conjunto binario:

$$Y \in \{0,1\}$$

Donde la clase activa ( $Y = 1$ ) representa conceptualmente al cliente que rescinde contractualmente sus servicios con la compañía, y la clase pasiva ( $Y = 0$ ) identifica al usuario que permanece fiel a la organización.

Para garantizar la validez científica del diseño experimental y asegurar una estimación imparcial del error de generalización, la arquitectura del software implementada en `src/data_preprocessing.py` ejecuta una separación estricta de la base de datos original en dos conjuntos disjuntos: un conjunto de entrenamiento (Train) equivalente al 80% de la muestra, y un conjunto de prueba de control (Test) correspondiente al 20% restante. La integridad de este proceso descansa sobre la parametrización explícita de una semilla de aleatoriedad (`random_state = 42`). En el ámbito de la ingeniería de datos, la fijación de esta semilla es un requisito mandatorio para garantizar la reproducibilidad experimental del pipeline; esto asegura que cualquier ejecución futura del código sobre la misma infraestructura genere exactamente la misma partición indexada, permitiendo la comparación legítima entre diferentes arquitecturas algorítmicas.

Asimismo, la partición se ejecuta aplicando una estrategia de muestreo estratificado basada en el vector de etiquetas corporativas (`stratify = y`). Dado que el fenómeno del Churn presenta un desbalance moderado de clases en el mercado real, la estratificación garantiza que tanto el set de entrenamiento como el de prueba conserven de forma precisa la proporción original de clientes fugitivos y estables, evitando el riesgo de sesgar el aprendizaje hacia la clase mayoritaria.

Este diseño metodológico aborda de raíz la prevención de la fuga de datos (Data Leakage), uno de los vicios conceptuales más severos en el modelamiento predictivo. La fuga de datos ocurre cuando información del conjunto de prueba, que teóricamente simula datos futuros y no vistos en producción, contamina el proceso de entrenamiento del algoritmo. Si un pipeline aplica transformaciones globales como el escalado estadístico (StandardScaler) o la codificación de variables categóricas (OneHotEncoder) sobre la totalidad del dataset antes de realizar la división, los estimadores globales como la media aritmética, la desviación estándar y las frecuencias de categoría ya habrán internalizado propiedades estadísticas de las filas de prueba.

Para mitigar este riesgo de forma absoluta, el sistema modularizado integra el ColumnTransformer estructurado en `src/pipeline.py` de manera estrictamente diferenciada. El pipeline ejecuta el método `fit_transform()` únicamente sobre la matriz de características de entrenamiento (`X_train_raw`), limitando el cálculo de los parámetros de distribución a dicho subconjunto. Posteriormente, el conjunto de prueba (`X_test_raw`) es procesado de manera puramente pasiva mediante el método `transform()`, utilizando exclusivamente las medias y varianzas heredadas del

set de entrenamiento. De este modo, el conjunto de Test permanece matemáticamente aislado, garantizando que la evaluación final del modelo refleje con honestidad su rendimiento ante datos del mundo real.

## 7.1 Implementación de Modelos Supervisados

Con el objetivo de explorar exhaustivamente el espacio de soluciones para la clasificación del abandono de clientes, se seleccionaron e implementaron cuatro modelos supervisados de diversa naturaleza matemática y estructural. A continuación, se expone la justificación técnica, ventajas, limitaciones y pertinencia de cada clasificador aplicado al dataset de Telco Churn.

### Regresión Logística

La Regresión Logística constituye el modelo de referencia basal (baseline) para problemas de clasificación binaria debido a su rigurosa fundamentación estadística y su alta interpretabilidad. El algoritmo modela la probabilidad posterior de la clase activa condicionada a un vector de características mediante la aplicación de la función sigmoide o logística sobre una combinación lineal de los predictores:

$$P(Y = 1 | X) = 1 / (1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)})$$

El proceso de optimización matemática busca maximizar la función de verosimilitud para encontrar el vector de coeficientes  $\beta$ . La ventaja fundamental de este modelo en la problemática del Churn es la relación directa entre sus coeficientes y el logaritmo de la razón de ventajas (log-odds). Esto permite mapear con precisión matemática cómo el incremento unitario en una variable, por ejemplo el cobro mensual, altera la probabilidad de fuga del cliente.

Su principal limitación radica en que asume linealidad en los log-odds, lo que le impide capturar interacciones complejas de alto orden entre variables sin ingeniería de características manual previa. Es altamente pertinente para este proyecto como modelo de control y perfilamiento inicial de riesgos.

### Random Forest

Pertenece a la familia de los métodos de ensamble basados en el aprendizaje por promediación, específicamente implementando la técnica de agregación bootstrap (bagging). El clasificador construye una estructura forestal compuesta por múltiples árboles de decisión independientes entrenados de forma paralela sobre submuestras aleatorias del dataset original. Adicionalmente, introduce aleatoriedad en la selección de características en cada división de nodo.

La ventaja medular de Random Forest para el conjunto de datos de telecomunicaciones es su capacidad intrínseca para modelar relaciones altamente no lineales y complejas interacciones cruzadas de variables sin requerir transformaciones matemáticas previas. Al promediar las predicciones de múltiples árboles, el modelo reduce drásticamente la varianza del sistema, mitigando el peligro de sobreajuste característico de los árboles individuales.

Su limitación principal reside en la pérdida de interpretabilidad directa, transformándose en un modelo de caja negra que requiere métricas de importancia de características para su auditoría.



Es sumamente pertinente para capturar los patrones ocultos y multivariados de la deserción de usuarios.

### **Decision Tree (Árbol de Decisión)**

El Árbol de Decisión es un modelo no paramétrico que particiona el espacio de características de forma recursiva y jerárquica mediante la inducción de reglas lógicas de decisión de arriba hacia abajo. En cada nodo intermedio, el algoritmo evalúa las características independientes y selecciona la división óptima que maximiza la ganancia de información o reduce la impureza de Gini:

$$\text{Gini}(D) = 1 - \sum (p_i^2)$$

Su ventaja más destacable es la transparencia absoluta y la facilidad para la explicación empresarial, puesto que las reglas de decisión resultantes adoptan una estructura condicional if-then-else que emula el razonamiento humano y puede ser traducida directamente a políticas comerciales en el departamento de retención.

Sin embargo, su limitación crítica es su alta inestabilidad y propensión al sobreajuste. Pequeñas variaciones en los datos de entrenamiento pueden alterar radicalmente la arquitectura del árbol, generando modelos de alta varianza si no se aplican técnicas estrictas de poda o restricciones de profundidad mínima. Su pertinencia radica en proporcionar un mapa visual explícito de los caminos lógicos que conducen a la fuga de clientes.

### **K-Nearest Neighbors (KNN)**

El algoritmo de los K-Vecinos Más Cercanos es un clasificador basado en instancias y de naturaleza no paramétrica, clasificado dentro de los métodos de aprendizaje perezoso (lazy learning), ya que no construye un modelo matemático explícito durante la fase de entrenamiento, sino que delega todo el costo computacional a la fase de inferencia.

Ante un cliente del conjunto de prueba, el algoritmo calcula la distancia geométrica, típicamente la distancia euclidiana, entre dicho punto y todos los registros del conjunto de entrenamiento:


$$d(x,q) = \sqrt{\sum (x_i - q_i)^2}$$

Posteriormente, selecciona los K registros más próximos y asigna la clase mediante una votación mayoritaria.

La ventaja principal de KNN es su simplicidad teórica y su capacidad para adaptarse orgánicamente a fronteras de decisión extremadamente complejas e irregulares. Su limitación fundamental es su sensibilidad crítica al escalado de las variables numéricas. Si variables con magnitudes elevadas no son rigurosamente estandarizadas mediante el StandardScaler, estas dominarán la métrica de distancia anulando el impacto de variables más acotadas.

Además, presenta un costo computacional elevado en datasets de gran volumen. Es pertinente para evaluar la existencia de vecindades o perfiles de clientes con comportamientos de consumo similares en el espacio vectorial.

## Gráficos del modelo




## 8. TÉCNICAS NO SUPERVISADAS

La exploración de patrones ocultos y la estructuración macro de los perfiles de los clientes se abordó mediante el uso de algoritmos de aprendizaje no supervisado. El objetivo de esta fase dentro del contexto del negocio consiste en segmentar la base de usuarios en grupos homogéneos basados en sus atributos comerciales, temporales y contractuales, proveyendo un marco de referencia complementario para contextualizar las alertas de riesgo generadas por la fase predictiva supervisada.

### 8.2 K-MEANS



Para la partición del espacio de características se seleccionó el algoritmo K-Means. La determinación del número óptimo de agrupaciones se fundamentó de manera empírica a través de la convergencia del Método del Codo y el análisis del Coeficiente de Silueta (Silhouette Score). Ambos indicadores matemáticos respaldaron la selección de una solución final estructurada en  $K = 3$  clústeres. El análisis multidimensional de los centroides y la distribución de las variables contractuales permitió establecer la caracterización técnica de cada segmento de la siguiente manera:



**Clúster 0:** Clientes consolidados de alto valor. Este segmento presenta los promedios cuantitativos más elevados del conjunto de datos, registrando una antigüedad media (tenure) de 55.08 meses, cargos mensuales promedio (MonthlyCharges) de 89.43 y una facturación acumulada promedio (TotalCharges) de 4930.28. Contractualmente, exhibe una baja concentración en la modalidad de mes a mes (Month-to-month = 24.66%), mientras que los compromisos a largo plazo son mayoritarios, distribuyéndose en un 33.61% de contratos a un año y un 41.72% de contratos a dos años. La probabilidad promedio de Churn calculada para este grupo es de 0.432360, y la tasa de rotación real observada se sitúa en un 15.29%.


**Clúster 1:** Clientes de bajo consumo. Esta agrupación está definida por usuarios con niveles de facturación reducidos. Los registros muestran una antigüedad media de 30.55 meses, cargos mensuales promedio de 21.08 y una facturación acumulada promedio de 662.60. La estructura de sus contratos se distribuye en un 34.34% para la modalidad mensual (Month-to-month), 23.85% para contratos anuales y un 41.81% para contratos a dos años. Este grupo destaca por registrar la menor tasa de rotación real observada en el proyecto, equivalente al 7.40%, asociada a una probabilidad promedio de Churn de 0.143193.

**Clúster 2:** Clientes recientes con alto riesgo de abandono. Este perfil se caracteriza por incorporar usuarios con baja permanencia temporal en la organización, documentando una antigüedad promedio de 16.18 meses, cargos mensuales promedio de 67.38 y una facturación acumulada de 1070.22. La vulnerabilidad de este segmento se refleja en su composición contractual, donde el 87.87% de los usuarios permanece bajo el esquema de mes a mes (Month-to-month), el 9.94% posee contratos a un año y únicamente el 2.19% cuenta con contratos a dos años. A pesar de registrar una probabilidad promedio de Churn de 0.070693 en el modelo, la tasa de rotación real observada es la más severa del proyecto, alcanzando el 44.27%, lo que valida la necesidad de priorizar intervenciones operativas sobre este grupo debido a su naturaleza inestable.



### 8.3 DENDROGRAMA Y CLUSTERING JERÁRQUICO

Con el propósito de complementar el análisis de partición y evaluar la consistencia estructural de los datos desde una perspectiva metodológica diferente, se implementó la técnica de Clustering Jerárquico Aglomerativo. El procesamiento y ordenamiento taxonómico de las instancias se visualizó mediante un dendrograma real generado en las fases analíticas del proyecto.



El dendrograma obtenido muestra una estructura jerárquica compatible con una solución final de 3 clústeres. Al trazar una línea de corte horizontal sobre los ejes de distancia, se observa la división del conjunto de datos en tres ramas principales. Este comportamiento gráfico aporta evidencia empírica que respalda la elección de  $K = 3$  previamente establecida mediante el algoritmo K-Means. En conformidad con los criterios de auditoría técnica y los datos disponibles, no es posible afirmar que los clústeres generados por ambos métodos sean idénticos, que repliquen exactamente las mismas distribuciones internas o que exista una validación perfecta entre ambos procedimientos, dado que dicha correspondencia exacta no fue demostrada por los resultados reportados en el proyecto.

## 9. Conclusiones

### 9.1. Análisis Multivariado de Trade-offs mediante Visualización Avanzada

La integración de las salidas de ambos modelos revela una correlación crítica entre la estructura demográfica/contractual del cliente y su propensión matemática al abandono. Al observar el boxplot de probabilidad de Churn cruzado por Clústeres y Tipos de Contrato, se concluye lo siguiente:

- **El Foco Crítico de Riesgo (Cluster 2 + Contratos Month-to-Month):** El Cluster 2, caracterizado previamente por clientes con altos cargos mensuales y servicios de fibra óptica, presenta una distribución de probabilidad de fuga que supera holgadamente el umbral crítico de 0.5, concentrándose de forma alarmante en los clientes con contratos de mes a mes. Esto prueba de manera empírica la hipótesis de negocio inicial: la combinación de altas tarifas y nula fidelización contractual genera la tormenta perfecta para la fuga.
- **El Grupo de Control Seguro (Clúster 1):** Independientemente del tipo de contrato, las probabilidades calculadas por el modelo supervisado para los integrantes del Cluster 1 (clientes históricos de alta permanencia) se sitúan consistentemente cercanas a cero, lo que ratifica la solidez estructural del algoritmo de segmentación.

### 9.2. Justificación de la Simulación Operativa del Umbral

La reducción del umbral de decisión a 0.35 aborda directamente la necesidad económica del negocio de telecomunicaciones, donde retener a un cliente existente mediante promociones reactivas es significativamente más barato que el Costo de Adquisición de Clientes (CAC) de un usuario nuevo.

Al desplazar el umbral hacia 0.35, el volumen de Falsos Negativos (clientes que el modelo clasificaba erróneamente como estables pero que terminaban abandonando la compañía) disminuyó drásticamente en la matriz de confusión optimizada. Este ajuste incrementa el Recall (Sensibilidad) de la clase Churn, permitiendo al equipo de retención de la compañía capturar de manera proactiva a una masa crítica de usuarios insatisfechos antes de que se consume la pérdida del ingreso recurrente.

### **9.3. Propuesta de Plan de Acción Comercial Basado en Modelos**

A partir de este cuaderno de consolidación final, se establecen las siguientes acciones directas para la toma de decisiones:

1. Acción Inmediata sobre el Cluster 2 (Contrato Mensual): Inyectar automáticamente a estos clientes en una campaña de retención prioritaria, ofreciendo bonos de descuento en sus cargos mensuales de fibra óptica condicionados a la firma de contratos de permanencia de un año (migración forzada al Clúster 1).
2. Monitoreo Preventivo sobre el Cluster 0: Utilizar el score probabilístico continuo del modelo supervisado para detectar de forma temprana a clientes nuevos de baja antigüedad cuya probabilidad comience a escalar sobre el valor 0.35, interviniendo con alertas operativas tempranas.